

【PDG2Seq: 用于交通流预测的周期动态图序列模型】

——【PDG2Seq: Periodic Dynamic Graph to Sequence Model for Traffic Flow Prediction】

1 相关资源

pdf: <https://doi.org/10.1016/j.neunet.2024.106941>

ppt:

短视频:

数据集:

源码: <https://github.com/wengwenchao123/PDG2Seq>

网站:

【除了网站，其他资源尽量下载】

2 论文属性

论文来源: Neural Networks 183 (2025) 106941

【给出具体会议名称和年限，不要仅仅写 ACM, IEEE】

论文类别: Neural Networks, Flow Prediction

【论文的类别，比如移动计算、轨迹处理、深度学习等】

论文关键字: Periodic features, Traffic flow prediction, Graph structure learning, Graph convolutional network, Spatio-temporal model

推荐程度: 2 （其他说明可标注）

(5 非常棒，建议认真研读、小组讨论和复现；4 好，建议细读，考虑复现；3 可以，部分内容值得注意；2 一般，简单浏览即可；1 没有意义，不建议阅读)

3 工作团队

作者: Jin Fan, Wenchao Weng, Qikai Chen, Huifeng Wu, Jia Wu

单位:

1. Hangzhou Dianzi University, Hangzhou, China
2. Zhejiang Provincial Key Laboratory of Industrial Internet in Discrete Industries, Hangzhou, China
3. Zhejiang University of Technology, Hangzhou, China
4. Macquarie University, Sydney, Australia

团队情况描述:

4 论文介绍

(1) 研究目的

【研究背景是什么？本文工作有什么用？】

交通流预测作为智能交通系统的核心任务之一，其目标是基于历史交通数据预测未来的交通状况。本文提出了一种名为 Periodic Dynamic Graph to Sequence Model (PDG2Seq) 的模型，旨在通过充分利用交通流的周期性特征和动态时空依赖关系，提高交通流预测的准确性。

(2) 研究现状

【当前的最好研究做到什么程度了？存在的问题是什么？这里采信论文的说法，可以给出自己的评点】

当前的交通流量预测研究已经取得了显著进展，尤其是在利用深度学习模型捕捉交通数据的非线性依赖关系方面。

早期的研究主要依赖于传统的统计模型和机器学习方法，如 ARIMA 和随机森林回归，但这些方法在处理非线性关系和高维数据时表现不佳。近年来，深度学习模型如 CNN、RNN 及其变体（如 LSTM 和 GRU）被广泛应用于交通流量预测，取得了较好的效果。此外，图神经网络（GNN）及其变体（如 GCN 和 GAT）也被证明在建模交通数据的图结构方面具有优势。

然而，现有方法仍然存在一些局限性，首先，大多数模型假设交通网络的空间相关性是静态的，而实际上这些相关性是动态变化的；其次，现有模型主要依赖历史数据进行预测，忽略了预测目标的周期性特征；最后，虽然交通数据具有明显的周期性，但现有方法对这些特征的利用不足。这些问题限制了现有模型在实际应用中的预测性能。

(3) 本文解决的问题

【一句话概括本文解决的核心问题】

本文旨在通过引入周期性特征和动态图结构，提高模型对交通流量变化的捕捉能力，从而实现更准确的交通流量预测。

(4) 创新与优势

【本文的创新之处是什么？新场景？新发现？新视角？新方法？请明确指出】

【本文工作的贡献或优点是什么？】

1. 周期性特征选择模块：能从历史数据中学习每个时间步的周期性特征，有效解决了周期性特征提取和利用的挑战。
2. 周期性动态图卷积门控循环单元：利用 PFSM 提取的周期性特征和交通流量的动态特征，生成周期性动态图，从而捕捉道路节点之间的动态关系。
3. 解码阶段的周期性特征利用：在解码阶段，PDG2Seq 利用与预测目标对应的周期性特征，从而更准确地捕捉未来趋势变化。

(5) 解决思路

【本文是怎样解决问题的？包括方法、技术、模型等，以自己理解的方式表述清楚】

本文提出的 PDG2Seq 模型主要通过五个方面实现交通流量预测中的动态时空相关性和周期性特征利用问题。

周期性特征选择模块（PFSM）

该模块主要用于提取数据中的周期性特征，来辅助预测

- 周期性特征池：引入连个周期性特征池，分别学习每日和每周的周期性特征
- 周期性索引函数：定义两个索引函数，分别用于获取当前时间步对应的每日和每周的周期性特征
- 特征提取：利用索引函数从特征池中提取当前时间步的周期性特征

$$e_{\text{daily}}(t) = E_{\text{daily}}[:, d(t)] \quad (1)$$

$$e_{\text{weekly}}(t) = E_{\text{weekly}}[:, w(t)] \quad (2)$$

周期性动态图生成

动态图可以反映交通的动态流量关系

- 动态信号提取：从交通流量数据中提取两个方向的信号，一种是流入的信号，一种是流出的信号
- 动态图嵌入：把提取的信号和规律信息结合起来，生成一种增强信号
- 图结构生成：在前两个步骤的基础上，用这些增强信号来构建一张动态地图，每个节点代表一个路口，连线代表流量关系

节点自适应参数学习

每个节点进行自适应的学习，可以让每个路口都学会属于自己的交通模式

- 节点嵌入矩阵：给每个路口分配一个标签，描述了该路口的交通特点
- 权重池：就是一个参数池，有着各种可能的交通模式
- 自适应参数生成：根据每个路口自己的标签，从参数池里挑选最适合它的参数，可以让每个路口都能用自己的方式描述交通流量

时空依赖建模

就是同时考虑空间和时间上的一个交通关系

- 动态周期图卷积：用动态地图来分析交通流量的空间关系，可以用图卷积来捕捉这些关系

$$H_{\text{in}}^{(l)}(t) = \text{GraphConv}(H^{(l-1)}(t), A_{\text{in}}(t), \Theta_{\text{in}}) \quad (3)$$

$$H_{\text{out}}^{(l)}(t) = \text{GraphConv}(H^{(l-1)}(t), A_{\text{out}}(t), \Theta_{\text{out}}) \quad (4)$$

- PDCGRU：结合了动态地图和 RNN，不仅能记住过去的流量变化，还能用动态地图来预测未来的流量

$$z_t = \sigma(W_z \cdot \text{GraphConv}(X_t, A(t)) + U_z \cdot h_{t-1}) \quad (5)$$

$$r_t = \sigma(W_r \cdot \text{GraphConv}(X_t, A(t)) + U_r \cdot h_{t-1}) \quad (6)$$

$$\tilde{h}_t = \tanh(W_h \cdot \text{GraphConv}(X_t, A(t)) + U_h \cdot (r_t \odot h_{t-1})) \quad (7)$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \quad (8)$$

计划采样训练策略

可以通过计划采样的这种训练策略，让模型在预测时更可靠

- 计划采样：就是在训练过程中，逐步减小对真实数据的依赖，让模型更多地依赖自己的预测结果
- 训练过程：在每次训练中，按一定概率用真实数据，一定概率用模型的预测结果，随着训练的进行，逐步减少用真实数据的频率

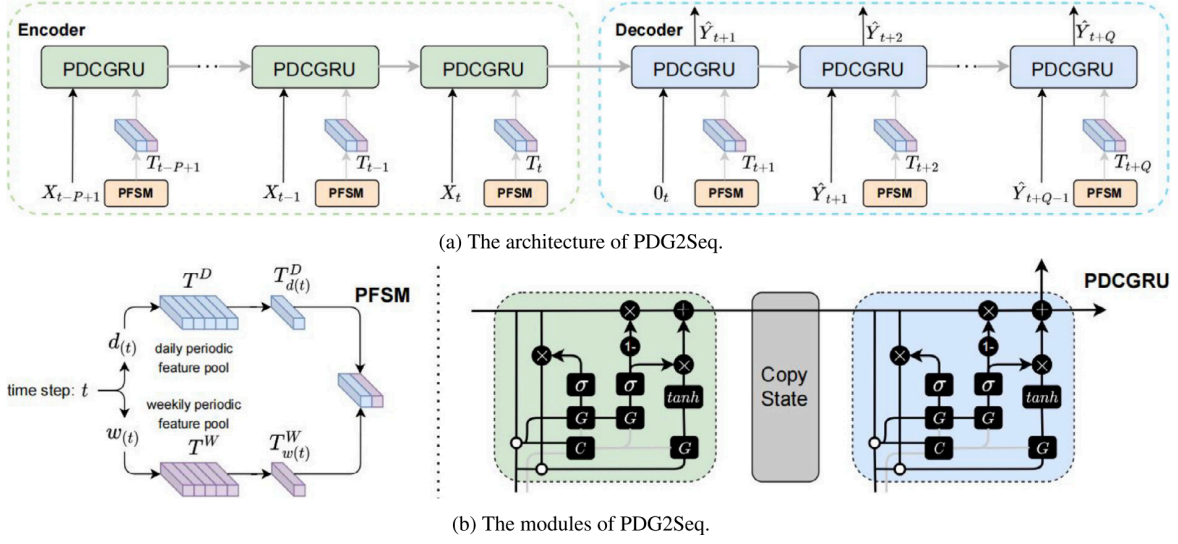


图 1: The architecture and modules of PDG2Seq.

算法的伪码如下：

Algorithm 1 Training algorithm of PDG2Seq.

Input: The traffic dataset O , encoder's recurrent function $f_{en}(\cdot)$, decoder's recurrent function $f_{de}(\cdot)$, decay size s , node embeddings E , scheduled sampling function $f_{ss}(\cdot)$

- 1: set $iter = 1$;
 - 2: **repeat**
 - 3: select a input $X \in R^{B \times P \times N \times C}$, label $Y \in R^{B \times Q \times N \times C}$, initialize hidden state H_0 , .
 - 4: compute $H_p = f_{en}(X, H_0)$.
 - 5: Initialize a zero tensor $Y_{in} \in R^{B \times N \times C}$ as the input to the decoder.
 - 6: **for** q in $0, 1, \dots, Q - 1$ **do**
 - 7: compute $Y_{in} = f_{de}(Y_{in}, H_{P+q})$.
 - 8: compute $\epsilon_i = f_{ss}(iter)$
 - 9: generate a random number $\mu \sim \mathcal{N}(0, 1)$.
 - 10: **if** $\mu < \epsilon_i$ **then**
 - 11: $Y_{in} = Y[:, q, :]$.
 - 12: **end if**
 - 13: **end for**
 - 14: Calculate loss L by using MAE.
 - 15: Update model parameters according to loss L .
 - 16: $iter = iter + 1$
 - 17: **until** convergence of the model is achieved
- Output:** learned model.
-

图 2: Training algorithm of PDG2Seq

(6) 可改进的地方

【本文工作的局限性是什么？你觉得可以从哪些方面改进工作？】

本文主要利用交通流量数据进行预测，我觉得可以融合其他的一些数据，比如天气等，来提高预测能力。

(7) 可借鉴的地方

【你觉得本文哪些方面可以借鉴？比如思路、方法、技术等】

本文通过引入周期性特征池和索引函数，可以更好的捕捉交通流量大的周期性变化，虽然方法大概了解，但是确实还不是很懂，不知道可不可以用于别的预测任务。

另外，我学到了计划采样训练策略，在训练过程逐步减少对真实数据的依赖，我觉得这个可以用于之后的训练任务中。

(8) 其他收获

【你有什么其他收获吗？比如了解了哪些团队和大牛在某领域做得很好，某类问题通常用什么技术解决，某些技术之间存在什么样的关联，某些会议和期刊在某领域很知名……】

我了解到在捕捉交通数据的复杂时空相关性和周期性特征方面，可以通过结合深度学习和图神经网络。

我觉得交通流量预测问题确实是挺复杂的，其实这篇文章也没有完全看懂，看完还是有点懵。

5 评阅人

姓名:

时间: