

# 【TimeCMA：通过跨模态对齐实现大语言模型赋能的多元时间序列预测】

—— 【TimeCMA: Towards LLM-Empowered Multivariate Time Series Forecasting via Cross-Modality Alignment】

## 1 相关资源

pdf: <https://arxiv.org/pdf/2406.01638.pdf>

ppt:

短视频:

数据集:

源码: <https://github.com/ChenxiLiu-HNU/TimeCMA>

网站:

【除了网站，其他资源尽量下载】

## 2 论文属性

论文来源: AAAI-25

【给出具体会议名称和年限，不要仅仅写 ACM, IEEE】

论文类别: Large Language Model, Time Series Forecasting

【论文的类别，比如移动计算、轨迹处理、深度学习等】

论文关键字: LLMs, Time Series Forecasting

推荐程度: 3 (其他说明可标注)

(5 非常棒，建议认真研读、小组讨论和复现；4 好，建议细读，考虑复现；3 可以，部分内容值得注意；2 一般，简单浏览即可；1 没有意义，不建议阅读)

## 3 工作团队

作者: Chenxi Liu, Qianxiong Xu, Hao Miao, Sun Yang, Lingzheng Zhang, Cheng Long, Ziyue Li, Rui Zhao

单位:

1. S-Lab, Nanyang Technological University, Singapore
2. Aalborg University, Denmark
3. Peking University, China
4. HKUST (Guangzhou), China
5. University of Cologne, Germany
6. SenseTime Research, China

团队情况描述:

## 4 论文介绍

### (1) 研究目的

**【研究背景是什么？本文工作有什么用？】**

本文主要研究多变量时间序列预测 (MTSF)。随着移动传感技术的飞速发展，交通、环境等诸多领域产生了海量的时间序列数据，这些数据蕴含着丰富的信息，能够帮助人们提前做出决策，例如在金融领域提前做出投资选择，在气象领域提前做好天气应对准备等。

然而，现有的统计方法和基于深度学习的方法在参数数量和训练数据规模上存在限制，导致预测性能和鲁棒性不足。近年来，将大型语言模型 (LLM) 与时间序列相结合的方法取得了显著进展，但现有基于 LLM 的解决方案在学习解耦嵌入方面存在不足。

因此，本文提出了 TimeCMA 框架，旨在通过跨模态对齐的方式，充分发挥 LLM 的优势，提升多变量时间序列预测的性能，为相关领域的决策提供更准确、更可靠的依据。

### (2) 研究现状

**【当前的最好研究做到什么程度了？存在的问题是什么？这里采信论文的说法，可以给出自己的评点】**

当前在多变量时间序列预测领域，基于深度学习的方法，如卷积神经网络和 Transformer，已经取得了显著进展。然而，这些方法受限于参数数量和训练数据规模，难以进一步提升性能。

近年来，大型语言模型 (LLM) 被引入到时间序列预测中，通过将时间序列与文本提示相结合，取得了比传统方法更好的效果。然而，现有的 LLM 方法存在数据纠缠问题，即时间序列嵌入和文本提示嵌入简单拼接后，输出嵌入变得纠缠，导致预测性能下降。此外，这些方法还面临着计算成本高、推理速度慢的问题，主要是因为多变量时间序列数据的双维度特性以及 LLM 输出的高计算负担。尽管有研究尝试通过冻结 LLM 的部分或全部参数来降低计算成本，但效果有限。

因此，如何解决数据纠缠问题以及降低计算成本，成为当前研究待解决的关键问题。

### (3) 本文解决的问题

**【一句话概括本文解决的核心问题】**

本文提出了 TimeCMA 框架，通过跨模态对齐的方式，从 LLM 中学习解耦嵌入，有效解决了数据纠缠问题。此外，本文还设计了一种特殊的提示，将时间序列数据封装在提示中，并将提示的最后一部分作为下游预测的输入，从而显著降低了计算成本。

### (4) 创新与优势

**【本文的创新之处是什么？新场景？新发现？新视角？新方法？请明确指出】**

**【本文工作的贡献或优点是什么？】**

- 揭示了时序预测中双模态 LLM 嵌入存在的数据纠缠问题，提出 TimeCMA 框架从文本-时序数据中学习解耦嵌入。
- 跨模态对齐模块通过通道相似性从 LLM 赋能的提示嵌入中提取解耦且鲁棒的时序嵌入以提升预测性能。
- 定制每个提示的末位标记来降低计算成本，并通过存储这些末位标记嵌入避免冻结 LLM 的重复处理，实现高效预测。

## (5) 解决思路

【本文是怎样解决问题的？包括方法、技术、模型等，以自己理解的方式表述清楚】

论文提出了一种名为 TimeCMA 的框架，用于多变量时间序列预测。该框架的核心思想是通过跨模态对齐，结合大模型和时间序列数据，学习解耦且鲁棒的时间序列嵌入，从而提升预测性能。具体来说，TimeCMA 包含三个关键模块：双模态编码、跨模态对齐、时间序列预测。




图 1: Overall Framework of TimeCMA.

### 双模态编码

该模块旨在分别提取时间序列的解耦嵌入和封装时间序列的提示嵌入，该模块又分为时间序列编码和 LLM 增强编码。

其中，时间序列编码主要是从历史时间序列数据中提取解耦的变量嵌入。首先进行倒置嵌入，即将每个变量的整个时间序列视为一个“token”，并将其转换为可学习的矩阵（首先对时间序列数据进行可逆实例归一化，使其均值为零、标准差为一，以减轻时间序列分布偏移的影响，然后通过一个线性变换和激活函数 ReLU，将归一化后的时间序列转换为嵌入矩阵）；然后使用一个轻量级的 Pre-LN Transformer 编码器来捕捉变量嵌入之间的复杂时间依赖关系。

LLM 增强编码分支的主要任务是将时间序列数据封装在提示中，并通过预训练的 LLM 提取提示嵌入。首先使用 GPT-2 作为 LLM，将时间序列数据封装在提示中，并通过 GPT-2 提取提示嵌入；然后使用一个与时间序列编码器相同结构的 Pre-LN Transformer 编码器来细化提示嵌入。

### 跨模态对齐

该模块主要是从提示嵌入中检索出解耦且鲁棒的时间序列嵌入。主要通过通道相似性检索来实现，即计算时间序列嵌入和提示嵌入之间的通道相似性矩阵，并基于此矩阵从提示嵌入中检索出解耦且鲁棒的时间序列嵌入。

具体来说，首先通过矩阵乘法和 softmax 函数计算通道相似性矩阵，然后通过矩阵乘法将提示嵌入的信息聚合到时间序列嵌入中，得到最终的解耦且鲁棒的时间序列嵌入。

### 时间序列预测

该模块的主要任务是利用解耦且鲁棒的时间序列嵌入进行未来时间序列的预测。

首先，使用一个轻量级的 Pre-LN Transformer 解码器来解码时间序列嵌入，并捕捉变量之间的依赖关系；然后，将解码器的输出嵌入输入到投影函数中，生成未来的预测值。

TimeCMA 的总体目标函数包括预测损失和正则化损失。

## (6) 可改进的地方

**【本文工作的局限性是什么？你觉得可以从哪些方面改进工作？】**

虽然存储最后一部分的嵌入能够加快推理速度，但在面对大规模数据时，存储和管理这些嵌入可能会带来一定的挑战。

#### (7) 可借鉴的地方

**【你觉得本文哪些方面可以借鉴？比如思路、方法、技术等】**

本文的跨模态对齐思想和特殊的提示设计为多变量时间序列预测领域提供了新的视角和方法。跨模态对齐能够有效地解决数据纠缠问题，这种思想可以借鉴到其他涉及多模态数据融合的任务中，如图像与文本的融合等。

#### (8) 其他收获

**【你有什么其他收获吗？比如了解了哪些团队和大牛在某领域做得很好，某类问题通常用什么技术解决，某些技术之间存在什么样的关联，某些会议和期刊在某领域很知名……】**

我了解到在时间序列预测领域，Transformer 架构及其变体被广泛应用，而 LLM 的引入则为提升预测性能提供了新的可能性。

## 5 评阅人

姓名:

时间: